

# Denoising de señales de electroencefalograma utilizando RLS y comparación con LMS

Francisco Basili  
Ingeniería Electrónica  
ITBA  
Buenos Aires, Argentina  
fbasili@itba.edu.ar

Sergio Andrés Peralta  
Ingeniería Electrónica  
ITBA  
Buenos Aires, Argentina  
speralta@itba.edu.ar

Kevin Amiel Wahle  
Ingeniería Electrónica  
ITBA  
Buenos Aires, Argentina  
kwahle@itba.edu.ar

**Resumen**—Este artículo presenta la implementación y resultados de un sistema de cancelación de interferencia diseñado para eliminar artefactos no deseados en señales de electroencefalograma (EEG). Se emplean los algoritmos Q-LMS y RLS con el objetivo de mejorar la calidad de las señales EEG, buscando el camino para poder lograr diagnósticos más precisos.

## I. INTRODUCCIÓN

El electroencefalograma (EEG) es una herramienta de gran utilidad en el estudio de la actividad cerebral y desempeña un papel fundamental en la investigación médica y clínica. Sin embargo, las señales de EEG frecuentemente se ven afectadas por interferencias no deseadas, que pueden obstaculizar una interpretación precisa. La presencia de artefactos musculares (EMG), artefactos oculares (EOG) y artefactos cardíacos (ECG), son comunes en los registros de EEG, lo que plantea una problemática para la obtención de información cerebral fiable. Estos artefactos se encuentran explicados más en profundidad en el proyecto previo de investigación [1], el cual se recomienda leer previo al presente informe, y se pueden observar en la Figura 1.




Figura 1: Obtención de señales de EEG, EOG y EMG [2].

El EEG cuenta con la característica de ser localmente estacionaria, lo que significa que sus propiedades estadísticas cambian lentamente con el tiempo, pero se mantienen estacionarias en intervalos de tiempo cortos [3]. En el caso del EEG, este período de estacionariedad local se estima típicamente en no más de 30 segundos.

## II. DESARROLLO

### II-A. Dataset

Se utilizó el MIT-BIH Polysomnographic Database [4], el cual cuenta con distintas grabaciones de señales fisiológicas durante el sueño. El conjunto de datos contiene más de 80 horas de grabaciones polysomnográficas con entre cuatro y siete canales, que incluyen señales de EEG, EOG (electrooculograma derecho), EMG y ECG.

De particular interés en este estudio es el conjunto de datos correspondientes al paciente 41 (slp41). Este conjunto cuenta con una frecuencia de muestreo de 250 Hz y tiene una duración de 6.5 horas (5,850,000 muestras de datos).

### II-B. Análisis y preprocesamiento de las señales

Para realizar el denoising se tomó un fragmento de 90 segundos de las señales originales. Si bien no cumple con el criterio de estacionariedad local establecido en la sección previa, se realizó un test de estacionariedad para comprobar la correcta selección de valores. El tiempo de los fragmentos debió ser necesariamente mayor al previamente establecido (30 segundos), debido al tiempo de convergencia de la señal resultante. En especial teniendo en cuenta la lentitud de la misma en RLS.

Resultó necesario adelantar temporalmente las señales de ECG y EOG para asegurar causalidad a la hora de aplicar los algoritmos. Los adelantos fueron de 10 y 400 muestras respectivamente. Las señales temporales resultantes y sus respectivos espectrogramas se pueden observar en las Figuras 2 y 3. Allí se evidencia una gran correlación en las señales, la cual ya se analizó en el informe previo.

El modelo a utilizar para lograr el denoising será el de cancelación de interferencia del tipo cascada [5], tal como se lo puede observar en la Figura 4.

Se procedió a analizar las correlaciones cruzadas entre el EEG y el ECG, y entre el EEG y el EOG. Esto permitió observar la relación entre las señales de manera cuantitativa e identificar para qué valores de lags (delay entre muestras) sucedía. También permitió verificar la causalidad de las señales y obtener un valor adecuado de orden de filtro  $M$ . Los resultados obtenidos se pueden observar en las Figuras 5 y 6. Allí se verifica que la correlación cruzada respecto al EOG




Figura 2: Señales temporales de EEG, ECG y EOG.

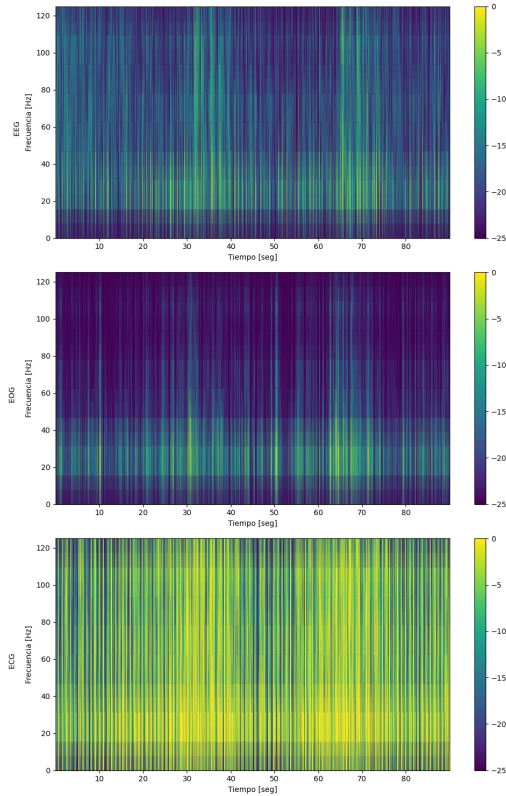


Figura 3: Espectrogramas de EEG, ECG y EOG.

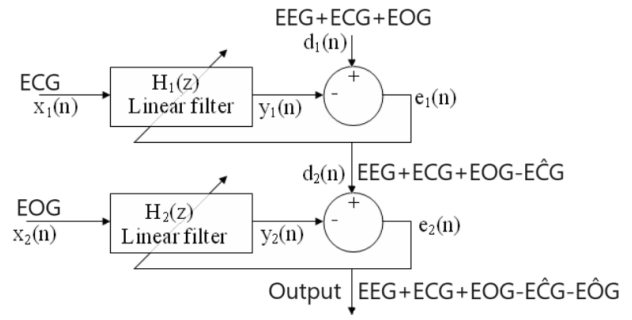


Figura 4: Modelo de cancelación de interferencia utilizado.

se extiende a mayores valores de lags en comparación a la obtenida respecto al ECG, por lo que se decidió utilizar un orden de filtro  $M_{ECG} = 15$  y  $M_{EOG} = 750$ .

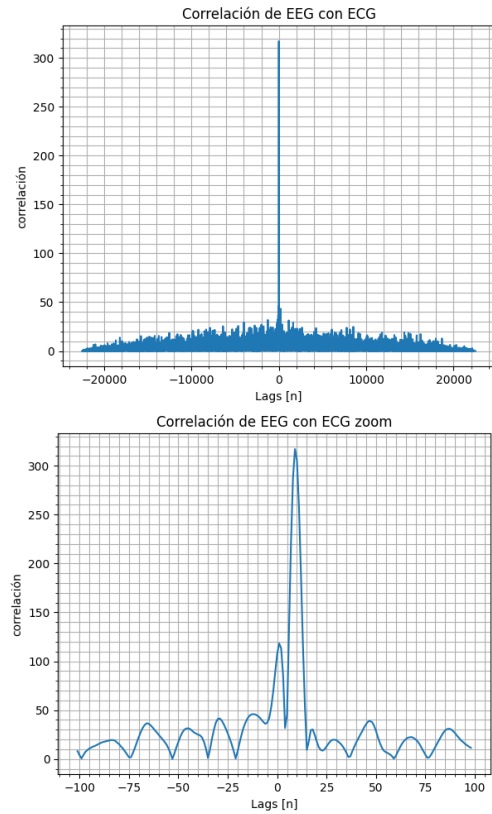


Figura 5: Correlación cruzada entre el EEG y el ECG.

Posteriormente se estimaron los autovalores de la matriz de autocorrelación del ECG y del EOG, para obtener una estimación del parámetro de paso y del spread de autovalores. Se obtuvieron los valores de la Ecuación 1, donde  $\lambda$  son los autovalores de la matriz de autocorrelación,  $\chi$  es el spread de autovalores y  $\mu$  es el parámetro de paso para el caso de LMS.




Figura 6: Correlación cruzada entre el EEG y el EOG.

$$\begin{aligned} \lambda_{maxECG} &= 7,64 \times 10^4 & \lambda_{maxEOG} &= 1,24 \times 10^5 \\ \mu_{maxECG} &= 2,62 \times 10^{-5} & \mu_{maxEOG} &= 1,62 \times 10^{-5} \\ \chi_{ECG} &= 2,94 \times 10^3 & \chi_{EOG} &= 1,5 \times 10^6 \end{aligned} \quad (1)$$

### II-C. Cuestiones a analizar

Durante el desarrollo del proyecto se destacaron ciertas cuestiones a tener en cuenta. Principalmente se notó una fuerte relación entre el orden del filtro elegido, la dificultad para hallar los parámetros óptimos y el tiempo de procesamiento del algoritmo: cuanto mayor era el valor de  $M$ , menor era el paso necesario para pasar de un estado de no alteración de la señal a la divergencia, y mayor era el tiempo de procesamiento en ambos algoritmos.

También se debieron tener en cuenta cuestiones relacionadas con las métricas. En esta aplicación, como la señal de interés está incluida en el error, ciertas métricas como la curva de aprendizaje no son aplicables. Dado que no disponíamos de una señal sin ruido como referencia, no fue posible calcular métricas estándar como el Error Cuadrático Medio (MSE) o la Relación Señal-Ruido (SNR), entre otras. Fue por ello que resultó necesario establecer una métrica propia para evaluar la calidad del proceso de filtrado. Esta métrica, denominada Factor de Mejora, se puede obtener a partir de la Ecuación 2, donde  $r_{x-y}$  es la correlación cruzada entre  $x$  e  $y$ , y  $\|a\|^2$  representa la energía de  $a$ .

$$FM_y = \frac{\|r_{EEG-y\{prefiltrado\}}\|^2}{\|r_{EEG-y\{postfiltrado\}}\|^2} \quad (2)$$

Además, se identificó que la señal contaba con una baja SNR, lo cual producía una convergencia muy lenta en RLS. Sin embargo, para realizar una comparación justa, se decidió tomar el mismo fragmento, de la misma duración, y utilizar un filtro del mismo orden para ambos casos. Sin embargo, es importante mencionar que todos estos parámetros (duración de la señal, orden del filtro, etc), fueron específicamente elegidos para maximizar el rendimiento de LMS, por lo cual, sumado a la baja SNR, no resulta extraño intuir que éste obtendrá un mejor resultado. Sin embargo, se analizará en mayor profundidad en las siguientes secciones.

### II-D. Q-LMS

Se aplicó Q-LMS (variante de LMS con la que se obtuvo el mejor resultado), teniendo en cuenta el modelo de la Figura 4 y los  $\mu_{max}$  calculados, aplicando una actualización de pesos dada por la Ecuación 3 [6] [7]. Fue necesario realizar un ajuste minucioso de los  $\mu$ , para lo cual se evaluó el factor de mejora para distintos valores. La actualización de pesos se define como :

$$\mathbf{w}(n+1) = \mathbf{w}(n) + \mu \cdot (q(n) + 1) \cdot x(n)e^*(n) \quad (3)$$

donde:

$$q_{upper} = \frac{2}{\mu \cdot \lambda_{máx}}$$

$$\psi(n+1) = \beta\psi(n) + \gamma e(n)^2, \quad (0 < \beta < 1, \gamma > 0)$$

$$q(n+1) = \begin{cases} q_{upper} & \text{if } \psi(n+1) > q_{upper} \\ 1 & \text{if } \psi(n+1) < 1 \\ \psi(n+1) & \text{otherwise} \end{cases}$$

Finalmente se tomaron valores de  $\mu$  que se encontrasen con cierto margen del estado de divergencia, siendo  $\mu_{ECG} = 1 \times 10^{-8}$ ,  $\mu_{EOG} = 1 \times 10^{-7}$ ,  $\beta = 0,5$  y  $\gamma = 5 \times 10^{-3}$ .

### II-E. RLS

Se procedió a realizar el mismo modelo de la figura 4, pero utilizando RLS como algoritmo para la actualización de pesos de los filtros adaptativos, manteniendo exactamente las mismas señales con las que se ingresó en el caso del algoritmo LMS y utilizando el mismo orden de filtro para poder realizar una comparación justa.


La inicialización de los valores para la matriz  $\mathbf{P}(-1)$  se realizó, en un principio tomando el valor  $\delta^{-1}\mathbf{I}$ , con  $\delta = \sigma_x^2(1 - \lambda)$ , pero esto resultaba en un gran salto en los valores iniciales de los coeficientes, en particular para el ECG. Por lo tanto, luego de algunos ajustes hasta conseguir resultados aceptables, se procedió a utilizar como valor de  $\delta$ , la media

de los valores de la diagonal de la matriz  $P(n)$  luego de terminada la adaptación. Esto resultó en la eliminación de este salto y el aumento de la velocidad de convergencia y el rendimiento general del algoritmo. Los pesos del filtro se inicializaron con el valor 0.


Los valores de  $\lambda$ , que ajusta la memoria del algoritmo, se obtuvieron mediante prueba y error, y se concluyó que los valores que mejor resultado arrojaron fueron los más chicos posibles, antes del límite de la inestabilidad, similar a lo ocurrido con  $\mu$  en LMS.

### III. RESULTADOS

Se procedió a realizar una comparación entre la señal de error y la señal de EEG original utilizando tanto Q-LMS como RLS, como se puede apreciar en la Figura 7.



(a) Q-LMS




(b) RLS

Figura 7: Error y EEG original para distintos algoritmos.


En estas representaciones, es evidente que ambos algoritmos logran un filtrado exitoso de los artefactos presentes en la señal original, en especial del ECG. A medida que transcurre el tiempo, se observa un progresivo aumento en el desempeño del filtrado de estos artefactos.

Se destaca que, en la Figura 7, que el algoritmo RLS no logra reducir los artefactos del EOG al mismo nivel que Q-LMS. Esta diferencia se hace más evidente en la Figura 8, donde se presenta tanto la señal original de EEG como la salida del filtro aplicado al EOG, la cual denota la señal correlacionada que va a ser eliminada.

Las diferencias observadas entre los algoritmos Q-LMS y RLS se pueden atribuir principalmente a la notable diferencia



(a) Q-LMS



(b) RLS

Figura 8:  $\hat{y}$  y EEG para distintos algoritmos.

en la velocidad de convergencia. En particular, el algoritmo RLS exhibe una convergencia más lenta en comparación con el algoritmo Q-LMS. Este fenómeno se manifiesta de manera más evidente en entornos caracterizados por una baja SNR. La presencia significativa de ruido en tales situaciones tiende a dificultar la capacidad del algoritmo RLS para alcanzar la convergencia y, por lo tanto, genera estimaciones de los coeficientes del filtro que son menos confiables en comparación con las obtenidas mediante el algoritmo Q-LMS.

Al no contar con acceso a la señal EEG original para calcular directamente la SNR, se desarrolló una estimación de la misma, utilizando como valor de señal la salida resultante del proceso de filtrado aplicado con el algoritmo Q-LMS.

De esta manera, hemos determinado que en el mejor escenario posible, que corresponde al momento del pico máximo de la señal del EOG (donde la señal se vuelve más distinguible en relación al ruido), la SNR se calcula como:

$$SNR = 10 \cdot \log(\text{señal}/\text{ruido}) \approx -3dB \quad (4)$$

Este valor de aproximadamente -3dB revela el hecho de que en RLS la convergencia será extremadamente lenta, por lo cual la estimación obtenida no será la óptima.

A su vez, también se puede observar que los valores de los coeficientes obtenidos son mayores en RLS, respecto a Q-LMS, tal como se puede observar en la Figura 9. A pesar de esto, los coeficientes ya no cuentan con el pico a los 66 segundos, como sí lo hace en Q-LMS.

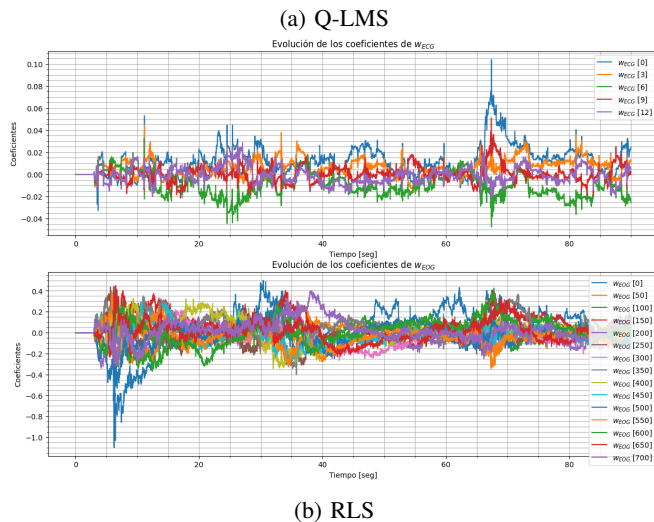



Figura 9: Variación de los coeficientes para ambas señales.

También se observó una enorme diferencia en cuanto al tiempo de procesamiento de la señal. Si bien es aceptable cierta demora, hay ciertos límites que ésta no puede exceder. Comparativamente el algoritmo de LMS resultó ser aproximadamente 100 veces más rápido respecto a RLS, lo cual es un factor notable.

Finalmente se calculó el factor de mejora (FM) para cada uno de los algoritmos. En las Figuras 10 y 11, se puede observar la correlación cruzada y la energía obtenida con la señal ya filtrada. Se notó una gran reducción de la misma, respecto a la observada en las Figuras 5 y 6, especialmente con el algoritmo Q-LMS.

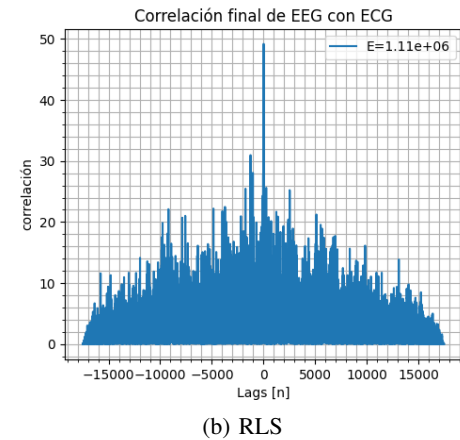
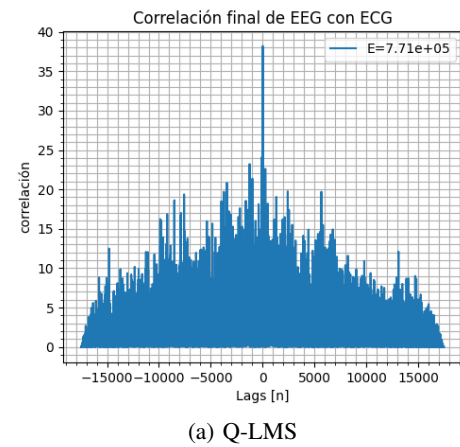


Figura 10: Correlación cruzada entre el EEG y el ECG.

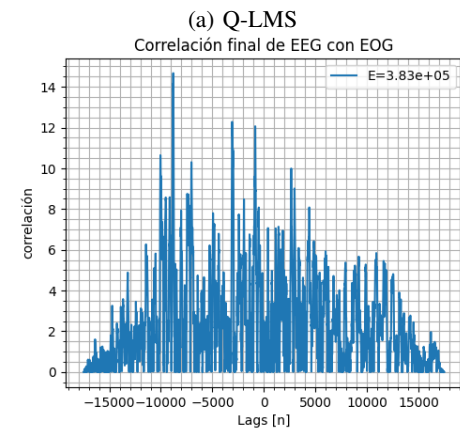
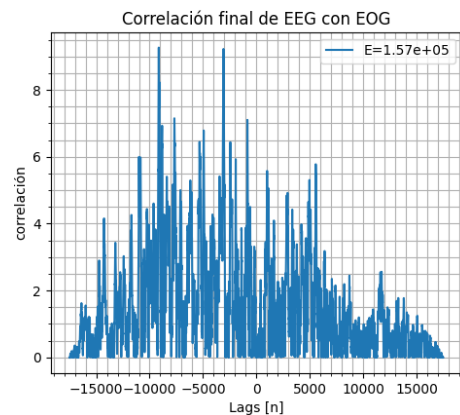


Figura 11: Correlación cruzada entre el EEG y el EOG.



En las Tablas I, II y III se presenta una comparación de los valores utilizados y los resultados obtenidos. En esta tabla, se destaca que el algoritmo que demostró un mejor rendimiento fue el de Q-LMS, ya que su Factor de Mejora (FM) resultó ser notablemente superior al de RLS.

ECG	$M_{ECG}$	$\mu_{ECG}$	$\delta_{ECG}$	$\tau_{ECG}$	$\beta$	$\gamma$	$FM_{ECG}$
Q-LMS	15	$1 \times 10^{-8}$	-	-	0,5	$5 \times 10^{-3}$	3,51
RLS	15	-	53191.5	450	-	-	2,45

Tabla I: Parámetros utilizados y resultados para ECG

EOG	$M_{EOG}$	$\mu_{EOG}$	$\delta_{EOG}$	$\tau_{EOG}$	$\beta$	$\gamma$	$FM_{EOG}$
Q-LMS	750	$1 \times 10^{-7}$	-	-	0,5	$5 \times 10^{-3}$	18,26
RLS	750	-	9.1	970	-	-	7,50

Tabla II: Parámetros utilizados y resultados para EOG

	Tiempo de procesamiento [seg]
Q-LMS	1.47
RLS	146.64

Tabla III: Resultados de tiempos

#### IV. CONCLUSIONES

A lo largo de este proyecto se desarrolló un modelo para la eliminación de los artefactos de ECG y EOG en el EEG. Luego de un exhaustivo análisis de las señales y consideraciones sobre la causalidad y correlación entre las señales, se implementaron algunas variantes de LMS, desarrolladas en un trabajo anterior, obteniendo los mejores resultados con Q-LMS.

En esta oportunidad, se presentó un enfoque distinto al mismo problema, mediante la aplicación del algoritmo RLS. Nuevos desafíos se presentaron a la hora de la elección de los parámetros, con algunas condiciones impuestas para poder realizar la comparación entre los diferentes algoritmos. En particular, la elección de la inicialización para la matriz  $\mathbf{P}$  introdujo algunas mejoras en los resultados.

Por último, se compararon en detalle estos dos enfoques, basados en estadísticos y en datos reales, para poder comprender cuáles son las ventajas y desventajas de cada uno y cuál resultó mejor en este caso y por qué.

A lo largo del desarrollo del presente informe, se pudo evidenciar que el algoritmo Q-LMS exhibió un desempeño superior. No obstante, resulta de gran importancia tener presente que la configuración del orden de los filtros, la segmentación y la longitud de la señal fueron determinados con base en el algoritmo LMS, otorgándole a este último una gran ventaja sobre el método RLS. La superioridad de Q-LMS no solo se fundamenta en el factor de mejora FM, sino también en una notable eficiencia temporal, evidenciada por un tiempo de procesamiento que resultó ser 100 veces más rápido en comparación con RLS.

Para futuras investigaciones, se sugiere la exploración de la aplicación de un algoritmo con características análogas a las de Q-LMS en el contexto de RLS. Este enfoque podría no solo lograr una mayor precisión en la eliminación de ruido, sino

también en una significativa reducción del tiempo de cálculo mediante la cuantificación.

#### REFERENCIAS

- [1] F. Basili, S. A. Peralta, and K. Wahle, "Denoising de señales de electroencefalograma utilizando lms y sus variantes," Instituto Tecnológico de Buenos Aires (ITBA), Buenos Aires, Argentina, Tech. Rep., Nov 2023.
- [2] L. Cutchen, "Diagnostic testing for sleep disorders," *University of New Mexico Hospitals Sleep Disorders Center*, 2016, november 11, 2016. [Online]. Available: <https://hsc.unm.edu/medicine/departments/pediatrics/divisions/continuum-of-care/pdf/cutchen--diagnostic-testing-for-sleep-disorders.pdf>
- [3] V. Ingle, S. Kogon, and D. Manolakis, *Statistical and Adaptive Signal Processing*, 2005.
- [4] G. Moody. (1999) Mit-bih polysomnographic database. Available at <https://physionet.org/content/slpdb/1.0.0/>. PhysioNet. Published: Aug. 3, 1999. Version: 1.0.0. [Online]. Available: <https://physionet.org/content/slpdb/1.0.0/>
- [5] A. G. Correa, E. Laciari, H. D. Patiño, and M. E. Valentinuzzi, "Artifact removal from eeg signals using adaptive filters in cascade," *Journal of Physics: Conference Series*, vol. 90, p. 012081, 2007, published under licence by IOP Publishing Ltd, 16TH ARGENTINE BIOENGINEERING CONGRESS (SABI 2007) AND THE 5TH CONFERENCE OF CLINICAL ENGINEERING, 26–28 September 2007, Alkazar Hotel, San Juan, Argentina. [Online]. Available: <https://iopscience.iop.org/article/10.1088/1742-6596/90/1/012081>
- [6] M. Arif, I. Naseem, M. Moinuddin, S. S. Khan, and M. M. Ammar, "Adaptive noise cancellation using q-lms," in *2017 International Conference on Innovations in Electrical Engineering and Computational Technologies (ICIEECT)*, 2017, pp. 1–4. [Online]. Available: <https://ieeexplore.ieee.org/document/7916527>
- [7] J. Hatala, "Artefacts removal from brain eeg signals using adaptive algorithms," 2021. [Online]. Available: <https://dspace.vutbr.cz/bitstream/handle/11012/211095/final-thesis.pdf>